Big Data & Data Analytics Prodi Psikologi Kelas III & IV

PERTEMUAN 4

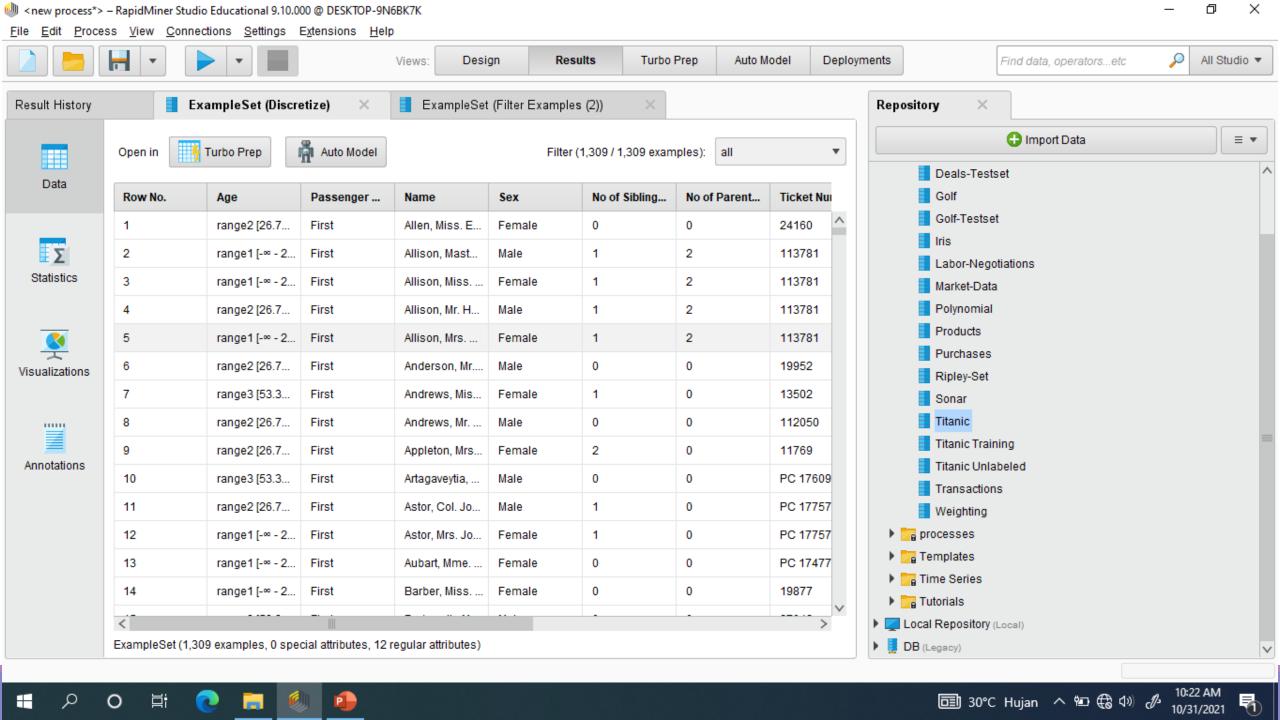
Data Cleansing

- Diskritisasi Dengan Binning
- Menghilangkan Missing Value
- Mengidentifikasi Outlier

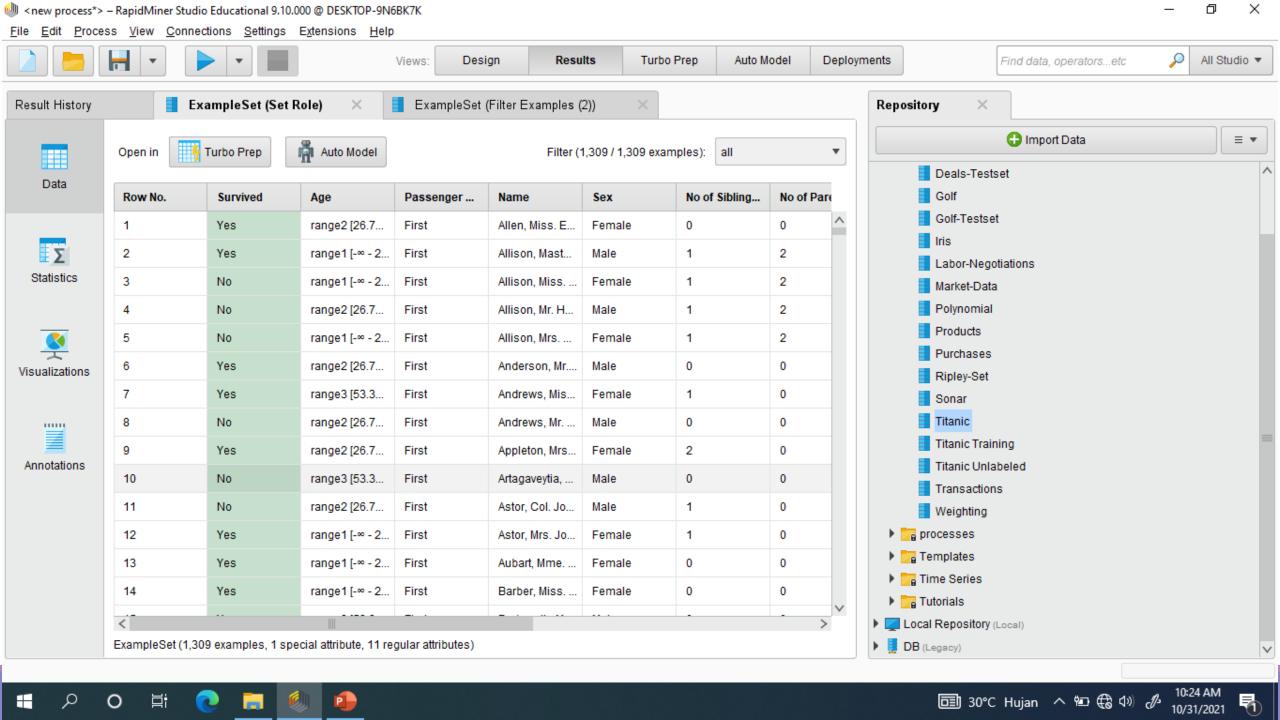
Diskritisasi Dengan Binning

Menggunakan Data "Titanic" Yang ada pada Repository di folder Sampel.

- Retrieve data "Titanic" lalu drag ke Panel Process
- Definisikan tipe attribute & Role :
- Pilih Operator "Discretize by Binning" Hubungkan dengan data Titanic
- Klik operator "Discretize by Binning" lalu isikan pada panel parameter
 - a. Attribute filter Type: Pilih Single (Karena hanya 1 yang akan kita kelompokkan)
 - b. Attribute to: Pilih Age
 - c. Number of Bins: Isilah dengan 3



- Definisikan attribute yang digunakan untuk memprediksi:
- Pilih Operator "Set Role" hubungkan dengan operator "Discretize by Binning"
- Klik operator "Set Role" lalu isikan pada panel parameter
 - a. Attribute Name: Pilih Survived
 - b. Role target : Ubah menjadi "label"
- ■Klik >



Menghilangkan Attribute/Kolom Dengan Banyak Missing Value

Menggunakan Dataset "Titanic" yang ada pada Repository Sampel.

Retrieve Data Titanic ke Panel Process
Letakkan Pointer ke Data Titanic lalu perhatikan bahwa ada 5 attribute yang memuat Missing Value
yaitu Age, Passenger Fare, Cabin, Port of Embarkation dan Life Boat.
□Pilih operator "Select Attributes" lalu Hubungkan dengan data Titanic
□Klik Operator Select Attributes, lalu pada panel Parameter :

- Attribute Filter Type: Pilih Subset (karena akan dihilangkan beberapa attribute)
- Pada Attributes klik Select Attribute pindahkan semua attribute kecuali Cabin & Life Boat
- Klik Apply
- ■Hubungkan ke Port Result Klik >

	Name	•• Type	Missing	Filter (10 / 10 attributes):	Search for Attributes
Data	✓ <u></u> Age	Real	263	Min 0.167	Max 80
Statistics	✓ No of Siblings or Spouses	on B Integer	0	Min O	Max 8
	✓ No of Parents or Children	on B Integer	0	Min O	Max 9
Visualizations	✓ Ticket Number	Polynominal	0	Least W/C 14208 (1)	Most CA. 2343 (11)
Annotations	✓ Passenger Fare	Numeric	1	Min O	_{Мах} 512.329
	✓ Port of Embarkation	Polynominal	2	Least Queenstown (123	Most) Southampton (9
	∨ Survived	Binominal	0	Negative Yes	Positive No

Pada Statistics terlihat masih ada Attribute yang mengandung Missing Value yaitu Age, Passenger Fare & Port of Embarkation

Me-Replace Missing Value.

- ☐ Pilih Operator "Replace Missing Values" Hubungkan dengan Operator "Select Attributes"
- Klik Operator Replace Missing Values, lalu pada panel Parameter :
 - Attribute Filter Type : Pilih Single (karena akan dihilangkan 1 attribute)
 - Pada Attributes pilih Age
- ■Hubungkan ke Port Result Klik >

Pada Statistics terlihat bahwa pada Attribute Age sudah tidak memuat Missing Value. Tetapi masih ada attribute Passenger Fare & Port of Embarkation yang memuat missing value dan harus dihilangkan.

Me-Remove Examples/Baris Yang Memuat Missing Value.

- □ Pilih Operator "Filter Examples" Hubungkan dengan Operator "Replace Missing Values"
- Klik Operator Filter Examples, lalu pada panel Parameter :
 - Condition class : pilih "no_missing_attributes"
- □ Hubungkan ke Port Result Klik ▷

Pada Statistics terlihat bahwa seluruh attribute sudah tidak memuat missing value.

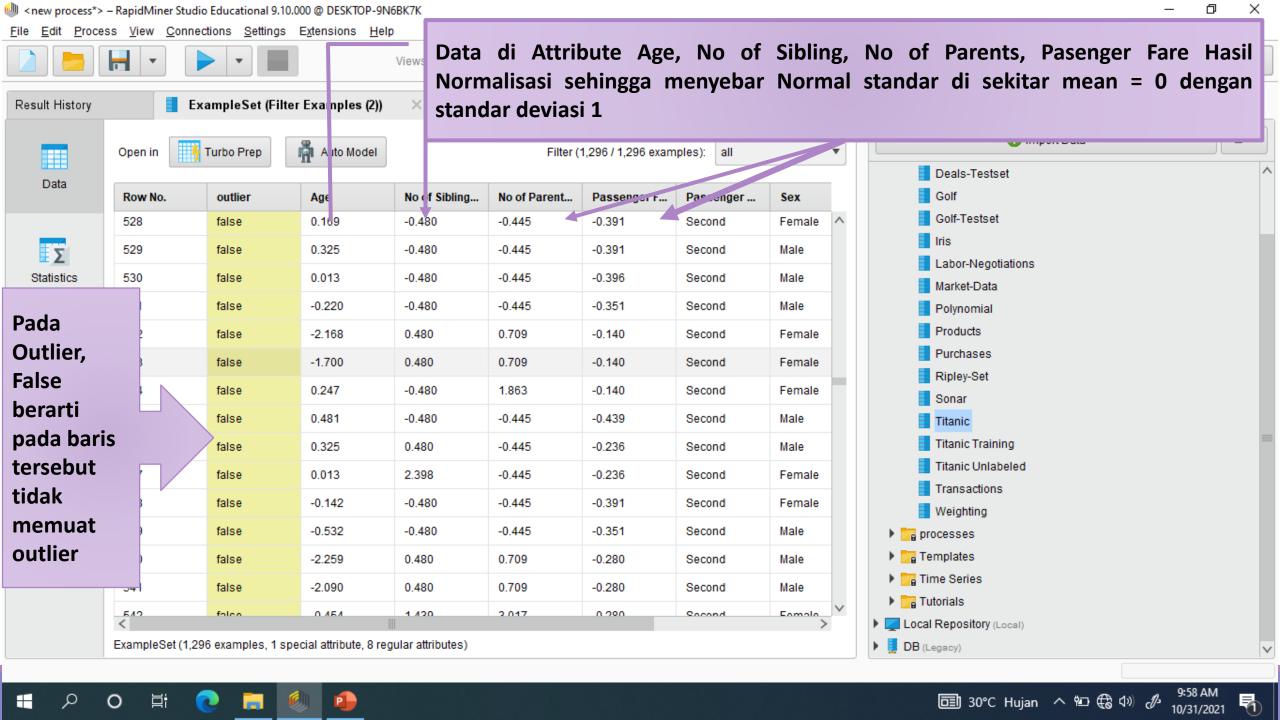
Mengidentifikasi Outlier

- > Tujuan: Mengidentifikasi kasus yang tak biasa (adanya outlier, dsb) dan membuangnya dari data set.
- ➤ Menggunakan Dataset "Titanic" yang sudah dilakukan cleansing.
- ☐ Pilih operator "Select Attributes" Hubungkan dengan operator "Replace Missing Values"
- Klik Operator Select Attributes, lalu pada panel Parameter :
 - Attribute Filter Type : Pilih Subset (karena akan dihilangkan beberapa attribute)
 - Pada Attributes klik Select Attribute pindahkan semua attribute kecuali Name & Ticket Number
 - Klik Apply
- □ Hubungkan ke Port Result Klik ▷

Diperoleh Dataset yang hanya memuat attribute-attribute yang berkontribusi dalam deteksi outlier.

Melakukan Normalisasi Data

Normalisasi Data adalah proses mengubah attribute menggunakan rentang nilai yang sama sedemikian sehingga
data tersebut akan menyebar normal.
□Pilih Operator "Normalized" – Hubungkan dengan Operator "Select Attributes"
□ Pilih Operator "Detect Outlier (Distances)" - Isikan Number of Neighbour =10, Number of outliers =10, distance function= Euclidian distance – Hubungkan dengan Operator "Normalized"
□Pilih Operator "Filter Examples" – Hubungkan dengan Operator "Detect Outlier (Distances"
□Klik Operator Filter Examples, lalu pada panel Parameter :
■ Filter: Klik Add a New Filter — Pilih Outlier (Kiri), Equals (tengah), False (Kanan)
□Hubungkan ke Port Result – Klik ⊳



Data Blending

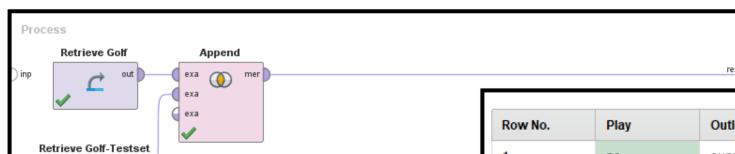
Menggabungkan Data Set dengan Join, Append, Set Minus,

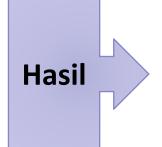
Intersect, Union, Cartesian Product

Menggabungkan Data Set Dengan Appends

- ➤ Operator Appends digunakan untuk menggabungkan beberapa data set yang memiliki attribute yang sama sehingga barisnya (Example) bertambah.
- □ Retrieve data "Golf" (14 baris) dan "Golf Testset" (14 baris) ke panel process
- ☐ Pilih operator "Appends" Hubungkan dengan kedua data tersebut
- ■Klik ▷

Hasil: dataset dengan 28 baris



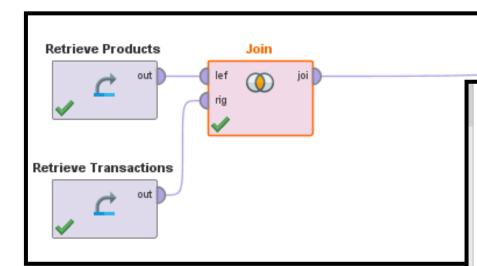


Row No.	Play	Outlook	Temperature	Humidity	Wind		
1	no	sunny	85	85	false		
2	no	sunny	80	90	true		
3	yes	overcast	83	78	false		
4	yes	rain	70	96	false		
5	yes	rain	68	80	false		
6	no	rain	65	70	true		
7	yes	overcast	64	65	true		
8	no	sunny	72	95	false		
9	yes	sunny	69	70	false		
10	yes	rain	75	80	false		
11	yes	sunny	75	70	true		
12	yes	overcast	72	90	true		
13	yes	overcast	81	75	false		
14	no	rain	71	80	true		
15	yes	sunny	85	85	false		
ExampleSet (28 examples, 1 special attribute, 4 regular attributes)							

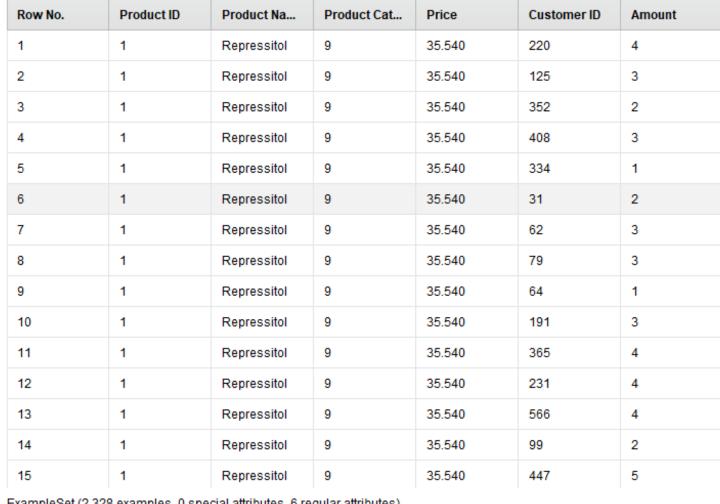
Menggabungkan Data Set Dengan Join

Operator Join digunakan untuk menggabungkan beberapa data set yang memiliki key attribute
(seperti primary key) yang sama sehingga attributenya bertambah.
Retrieve data "Transactions" dan "Products" (14 baris) yang keduanya memiliki key attribute

- yang sama yaitu product id.
- ☐ Pilih operator "Joins" Hubungkan dengan kedua data tersebut
- □ Pada parameter Key Attributes : Klik Edit List Isikan Left Key & Right Key dengan Product ID
- ■Klik >



Hasil

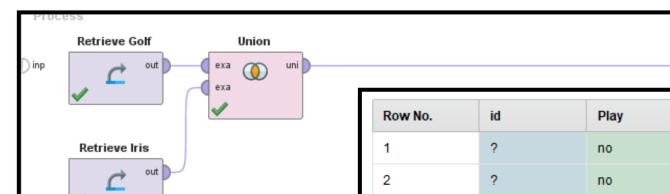


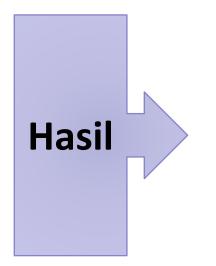
ExampleSet (2,328 examples, 0 special attributes, 6 regular attributes)

Menggabungkan Data Set Dengan Union

- ➤ Operator Union digunakan untuk menggabungkan beberapa data set yang memiliki attribute yang sama sehingga baris (Example) & Kolom (Attribute) bertambah.
- Retrieve data "Golf" dan "Iris" ke panel process
- □ Pilih operator "Union" Hubungkan dengan kedua data tersebut
- ■Klik >

Hasil: dataset dengan 28 baris





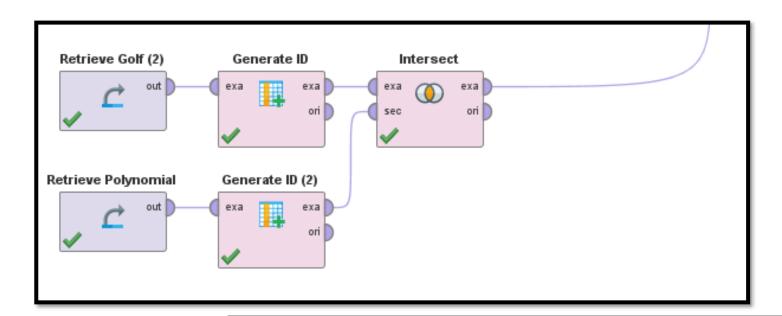
Row No.	id	Play	Outlook	Temperature	Humidity	Wind	a1
1	?	no	sunny	85	85	false	?
2	?	no	sunny	80	90	true	?
3	?	yes	overcast	83	78	false	?
4	?	yes	rain	70	96	false	?
5	?	yes	rain	68	80	false	?
6	?	no	rain	65	70	true	?
7	?	yes	overcast	64	65	true	?
8	?	no	sunny	72	95	false	?
9	?	yes	sunny	69	70	false	?
10	?	yes	rain	75	80	false	?
11	?	yes	sunny	75	70	true	?
12	?	yes	overcast	72	90	true	?
13	?	yes	overcast	81	75	false	?
14	?	no	rain	71	80	true	?
<		-		-		_	>

res

ExampleSet (164 examples, 2 special attributes, 8 regular attributes)

Mengkombinasikan Data Set Dengan Intersect (Irisan)

>Operator Intersect digunakan untuk melihat irisan atau data yang sama dari 2 data set. ☐ Retrieve data "Golf" dan "Polynomial" ke panel process □ Pilih operator generate ID – Hubungkan dengan data Golf – pada parameter isikan offset = 0 (artinya urutan dari data golf adalah 1 - 14) □ Pilih operator generate ID – Hubungkan dengan data Polynomial – pada parameter isikan offset = 10 (artinya urutan dari data polynomial dimulai dari 11 - 210) □ Pilih operator "Intersect" – Hubungkan dengan kedua Generate ID data tersebut ■Klik >



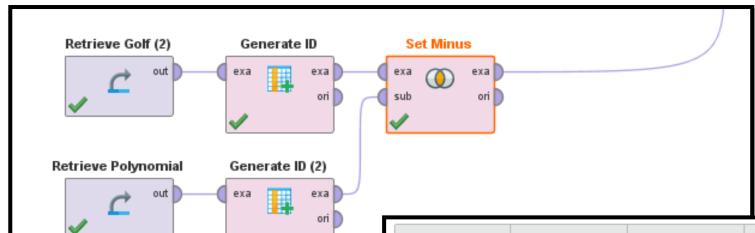




Row No.	id	Play	Outlook	Temperature	Humidity	Wind
1	11	yes	sunny	75	70	true
2	12	yes	overcast	72	90	true
3	13	yes	overcast	81	75	false
4	14	no	rain	71	80	true

Mengkombinasikan Data Set Dengan Set Minus

>Operator Set Minus digunakan untuk melihat isi dari dataset pertama tetapi yang tidak termuat d
dataset yang kedua.
Retrieve data "Golf" dan "Polynomial" ke panel process
\square Pilih operator generate ID — Hubungkan dengan data Golf — pada parameter isikan offset = 0 (artinya urutan dari data golf adalah 1 — 14)
□ Pilih operator generate ID – Hubungkan dengan data Polynomial – pada parameter isikan offset = 10 (artinya urutan dari data polynomial dimulai dari 11 – 210)
□Pilih operator "Set Minus" – Hubungkan dengan kedua Generate ID data tersebut
□Klik ⊳

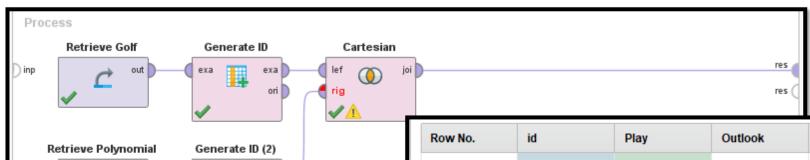




Row No.	id	Play	Outlook	Temperature	Humidity	Wind
1	1	no	sunny	85	85	false
2	2	no	sunny	80	90	true
3	3	yes	overcast	83	78	false
4	4	yes	rain	70	96	false
5	5	yes	rain	68	80	false
6	6	no	rain	65	70	true
7	7	yes	overcast	64	65	true
8	8	no	sunny	72	95	false
9	9	yes	sunny	69	70	false
10	10	yes	rain	75	80	false

Mengkombinasikan Data Set Dengan Cartesian Product

➤ Operator Cartesian Product digunakan untuk membuat kombinasi / pasangan berurutan dari
seluruh data di dataset 1 dengan seluruh data di dataset 2.
Retrieve data "Golf" dan "Polynomial" ke panel process
\square Pilih operator generate ID — Hubungkan dengan data Golf — pada parameter isikan offset = 0 (artinya urutan dari data golf adalah 1 — 14)
□ Pilih operator generate ID – Hubungkan dengan data Polynomial – pada parameter isikan offset = 10 (artinya urutan dari data polynomial dimulai dari 11 – 210)
□Pilih operator "Cartesian Product" – Hubungkan dengan kedua Generate ID data tersebut
□Klik ⊳





Row No.	id	Play	Outlook	Temperature	Humidity	Wind	a1		
1	1	no	sunny	85	85	false	0.637		
2	1	no	sunny	85	85	false	4.595		
3	1	no	sunny	85	85	false	4.292		
4	1	no	sunny	85	85	false	8.560		
5	1	no	sunny	85	85	false	2.272		
6	1	no	sunny	85	85	false	3.956		
7	1	no	sunny	85	85	false	2.220		
8	1	no	sunny	85	85	false	6.105		
9	1	no	sunny	85	85	false	2.691		
10	1	no	sunny	85	85	false	4.263		
11	1	no	sunny	85	85	false	1.364		
12	1	no	sunny	85	85	false	6.226		
13	1	no	sunny	85	85	false	9.812		
14	1	no	sunny	85	85	false	1.383		
<							>		
ExampleSet (2,80	ExampleSet (2,800 examples, 2 special attributes, 9 regular attributes)								

Big Data & Data Analytics Prodi Psikologi Kelas III & IV

PERTEMUAN 5

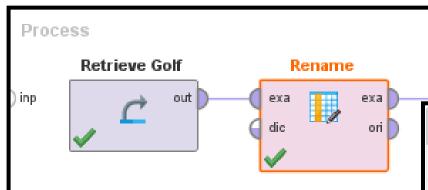
Rekayasa Attribute

- Me-Rename attribute
- Filter Data
- Mengubah Tipe Data

Mengubah Nama Attribute

Akan dilakukan perubahan nama attribute pada Data "Golf" menggunakan bahasa Indonesia

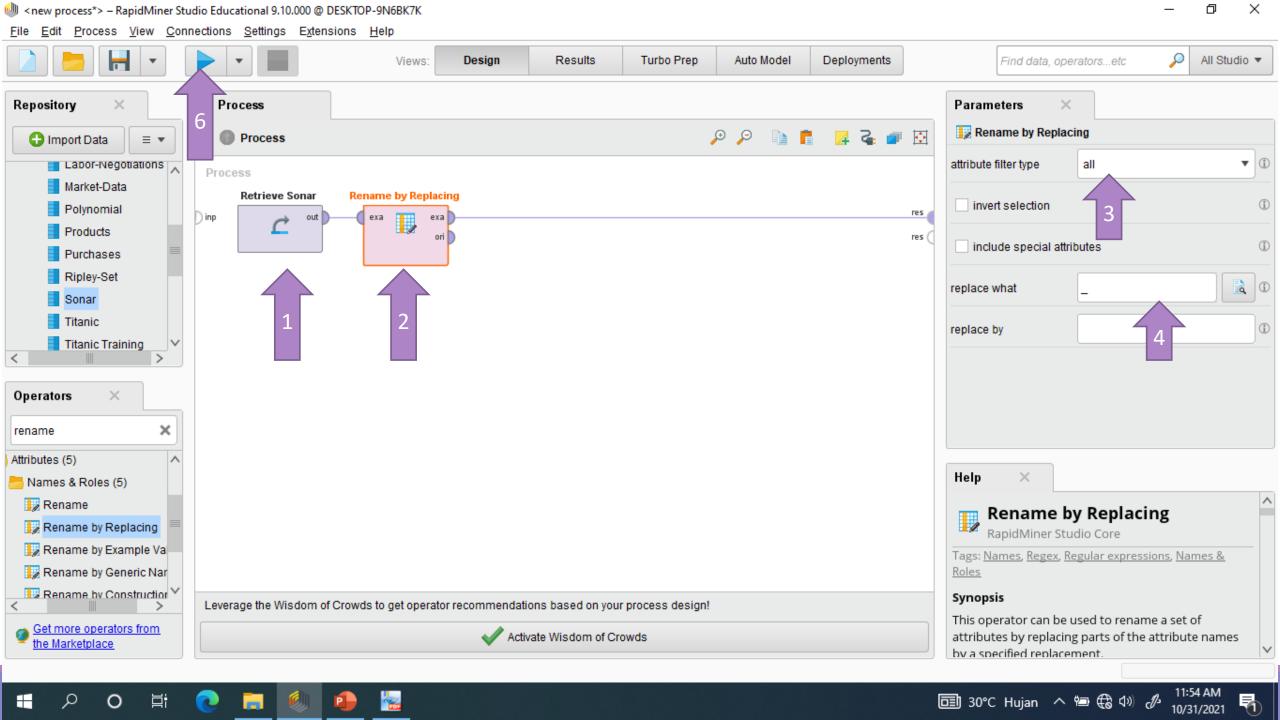
Retrieve Data "Golf" ke Panel Process ☐ Pilih Operator "Rename" — Hubungkan dengan data Golf Pada Parameter – Rename Attributes : Klik Edit List a. Old Name: Pilih "Play" – New Name: Ketikkan "Bermain" b. Old Name: Pilih "Humidity" – New Name: Ketikkan "Kelembaban" c. Old Name: Pilih "Outlook" – New Name: Ketikkan "Cuaca" d. Old Name: Pilih "Temperature" – New Name: Ketikkan "Suhu" e. Old Name : Pilih "Wind" – New Name : Ketikkan "Angin" □Klik apply ■Klik >

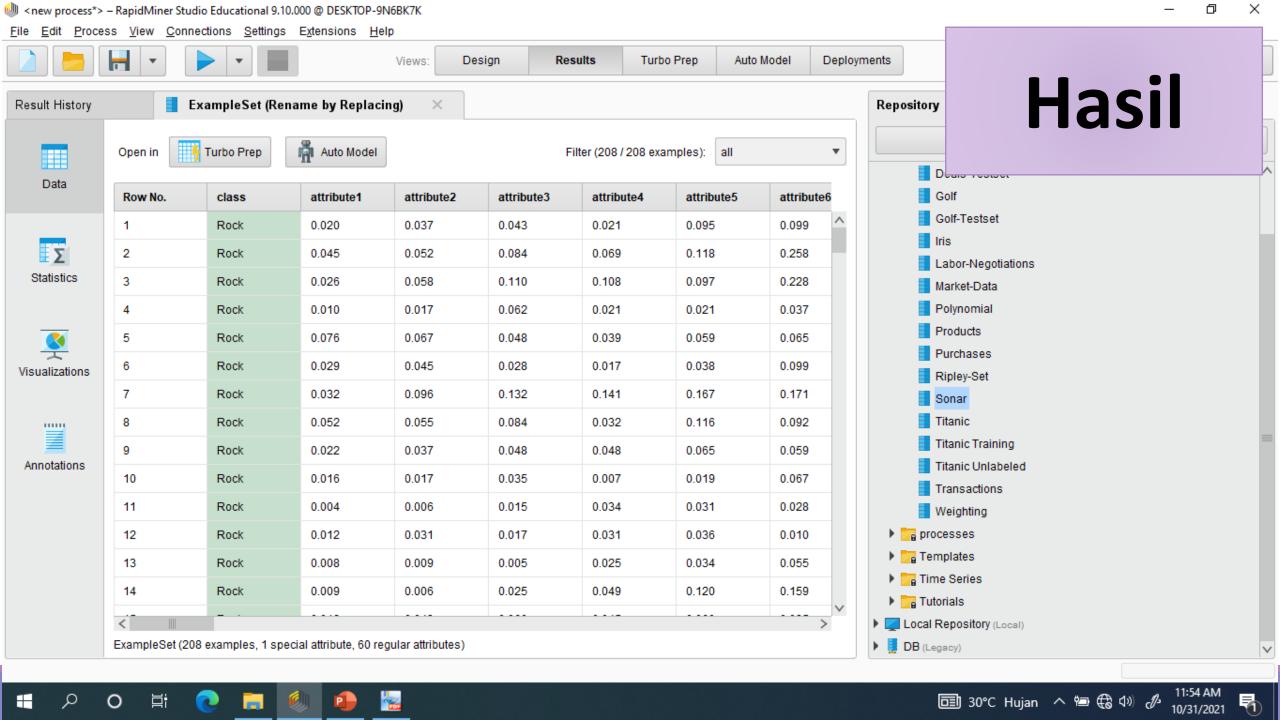


Hasil

Row No.	Bermain	Cuaca	Suhu	Kelembaban	Angin
1	no	sunny	85	85	false
2	no	sunny	80	90	true
3	yes	overcast	83	78	false
4	yes	rain	70	96	false
5	yes	rain	68	80	false
6	no	rain	65	70	true
7	yes	overcast	64	65	true
8	no	sunny	72	95	false
9	yes	sunny	69	70	false
10	yes	rain	75	80	false
11	yes	sunny	75	70	true
12	yes	overcast	72	90	true
13	yes	overcast	81	75	false
14	no	rain	71	80	true

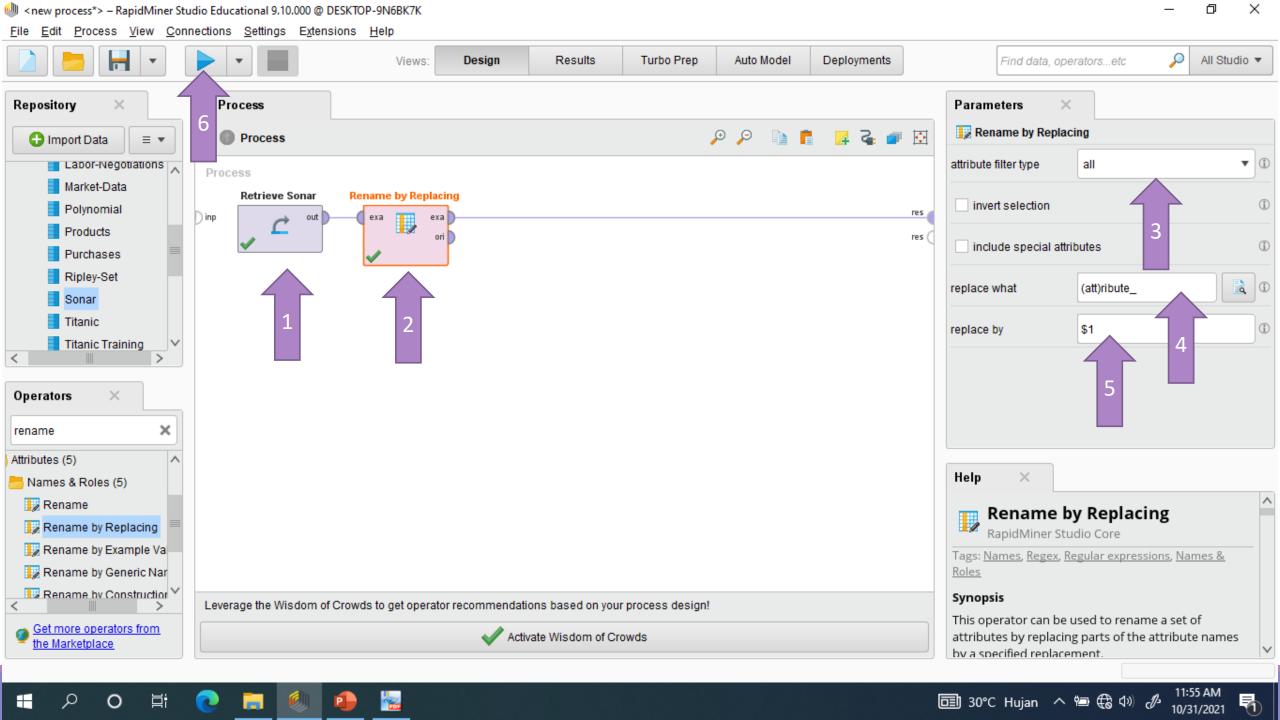
Akan dilakukan perubahan nama attribute pada Data "Sonar" dengan menghilangkan tanda "_"
Retrieve Data "Sonar" ke Panel Process
□Pilih Operator "Rename by Replacing" – Hubungkan dengan data Sonar
□Pada Parameter :
a. Attribute filter type : Pilih all (Karena akan diaplikasikan untuk semua atribut)
b. Replace what : Ketikkan dengan tanda underscore (_) (karena yang akan kita hilangkan tanda ini)
□Klik ⊳

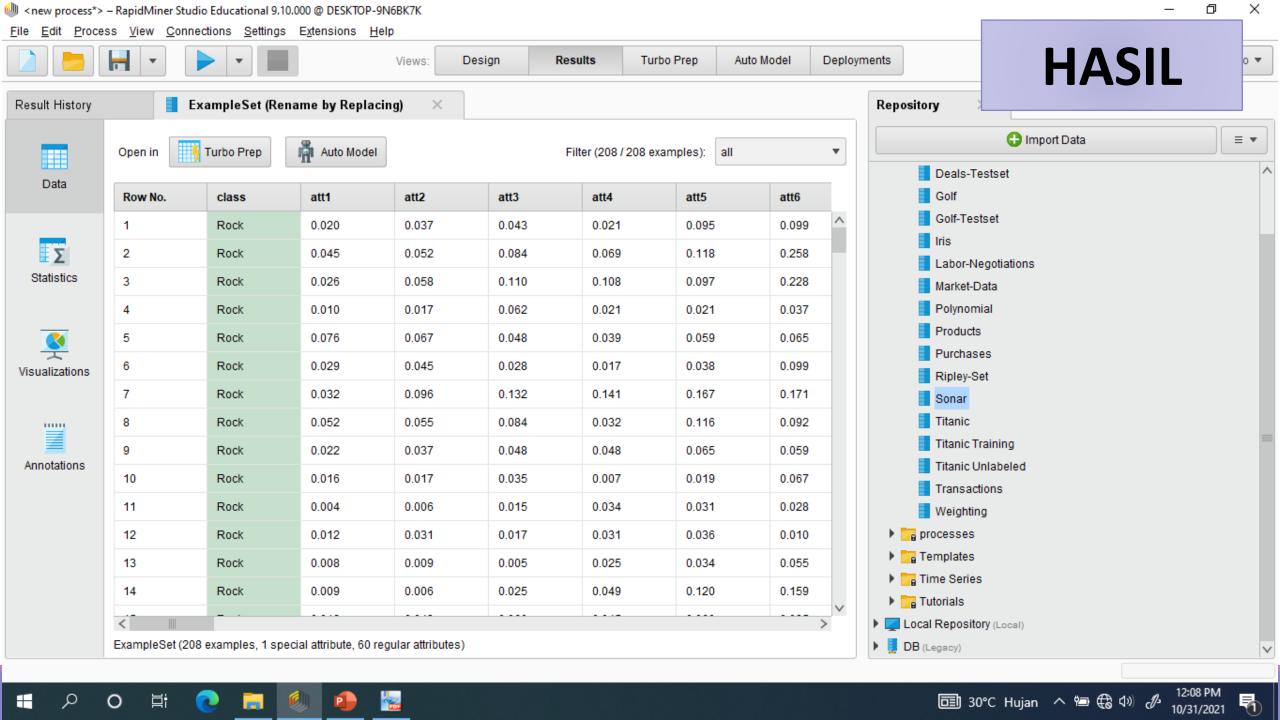




Akan dilakukan perubahan nama attribute pada Data "Sonar" dengan nama inisial "att1, att2,dst"
Retrieve Data "Sonar" ke Panel Process
□Pilih Operator "Rename by Replacing" – Hubungkan dengan data Sona
□ Pada Parameter :

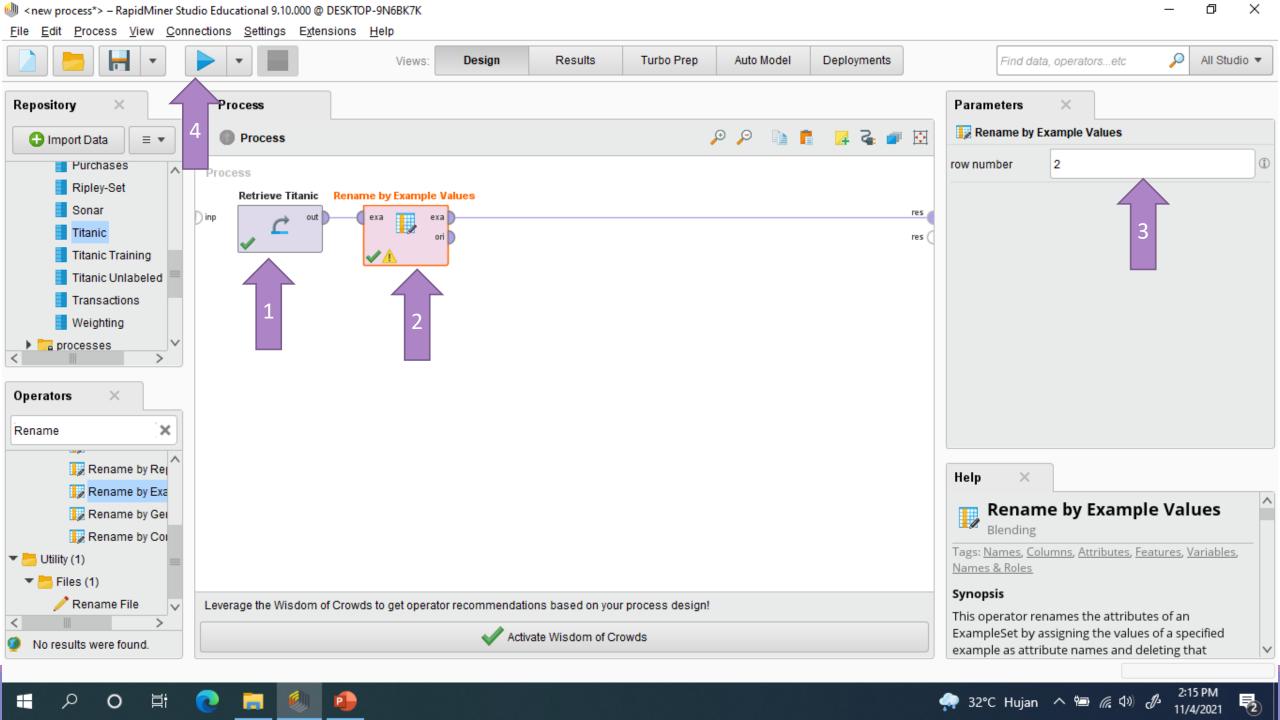
- a. Attribute filter type: Pilih all (Karena akan diaplikasikan untuk semua atribut)
- b. Replace what : Ketikkan dengan (att)ribute_ (karena yang kita ambil hanya att)
- c. Replace by: \$1
- ■Klik >

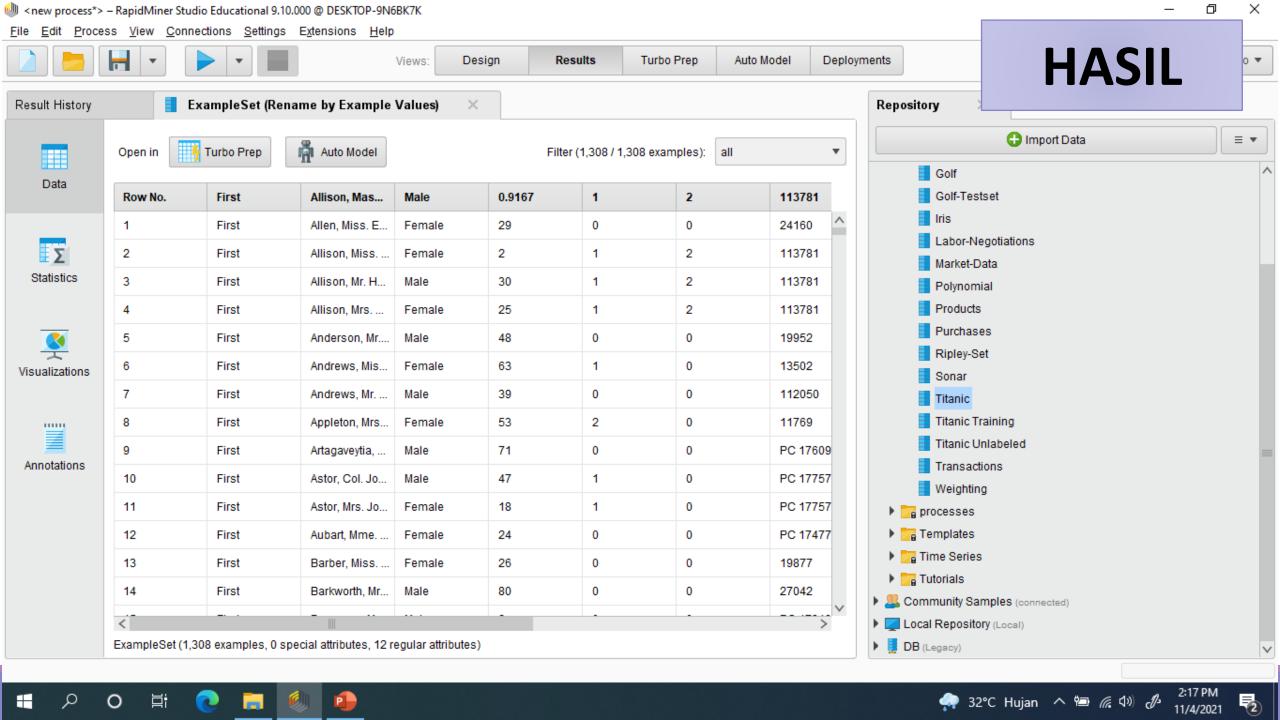




Akan dilakukan perubahan nama attribute pada Data "Titanic" dengan Baris Tertentu Pada Data Tersebut

- Retrieve Data "Titanic" ke Panel Process
- □ Pilih Operator "Rename by Examples Value" Hubungkan dengan data Titanic
- □ Pada Parameter : Row Number diisi dengan 3 (Misal dinamai dengan baris ketiga)
- ■Klik >



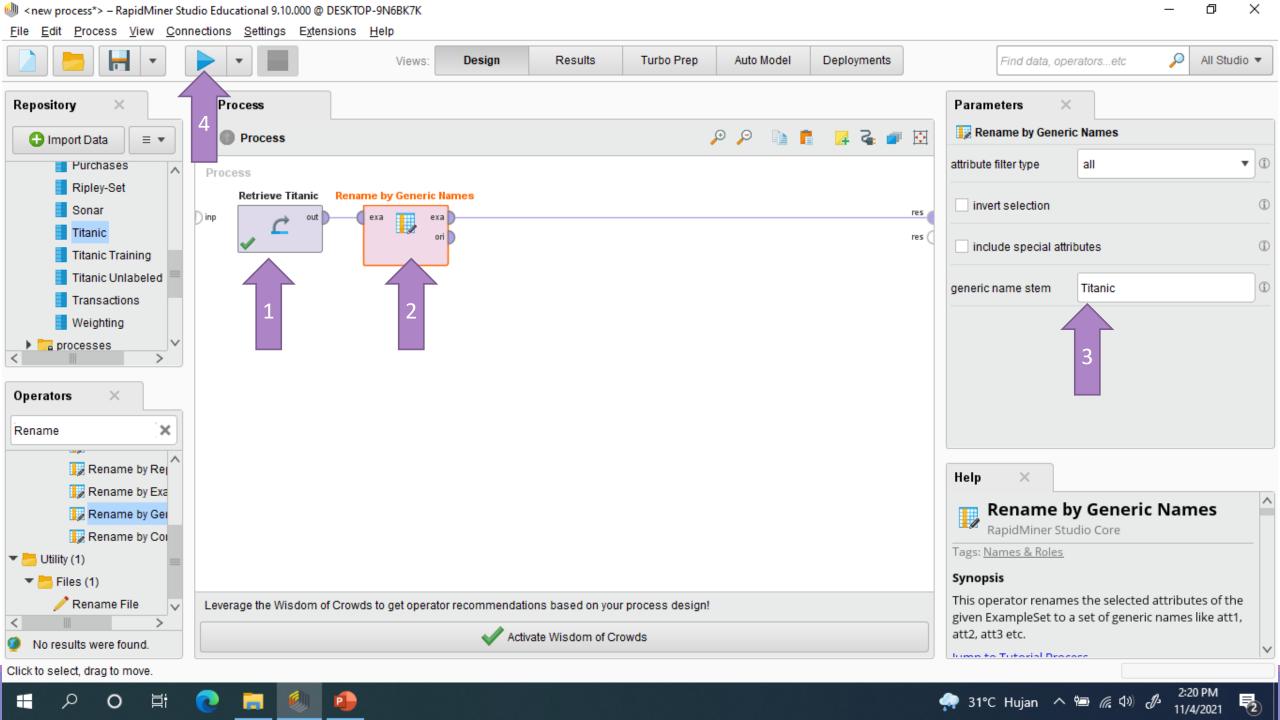


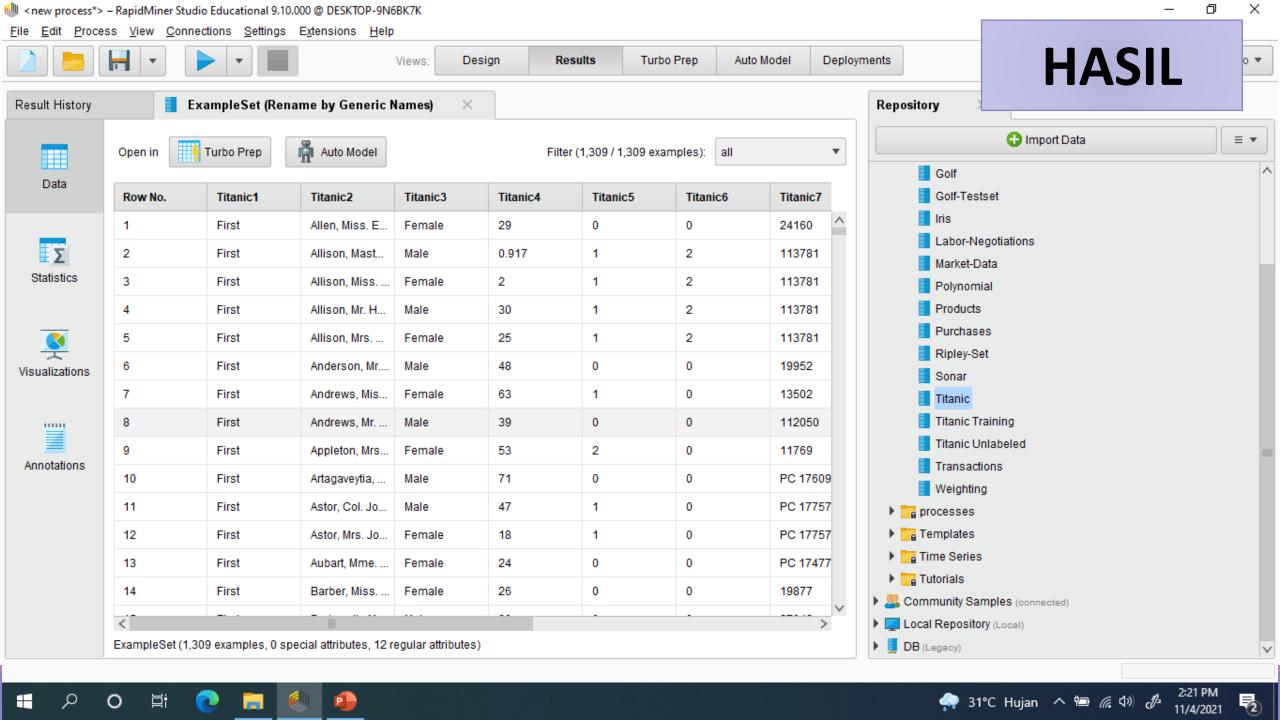
Akan dilakukan perubahan nama attribute pada Data "Titanic" dengan Generic Name

- Retrieve Data "Titanic" ke Panel Process
- □Pilih Operator "Rename by Generic Names" Hubungkan dengan data

Titanic

- ☐ Pada Parameter : Generic Name Stem diisi dengan Titanic (Misal)
- ■Klik >





Melakukan Filter By Ranges

Untuk menampilkan data set sesuai dengan Range/Rentang yang diinginkan

- Retrieve Data "Titanic" Pada Panel Proses
- ☐ Pilih Operator "Filter by Ranges" Klik
- Pada Parameter :
 - First Example : 3
 - Last Example: 10
- □Klik ⊳

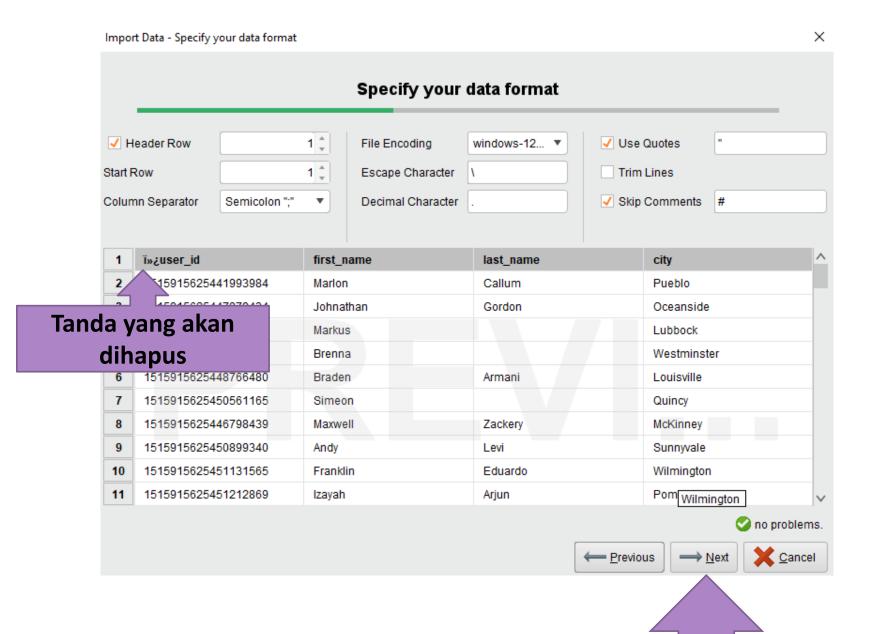
Menghilangkan Simbol Tidak Berguna Pada Attribute

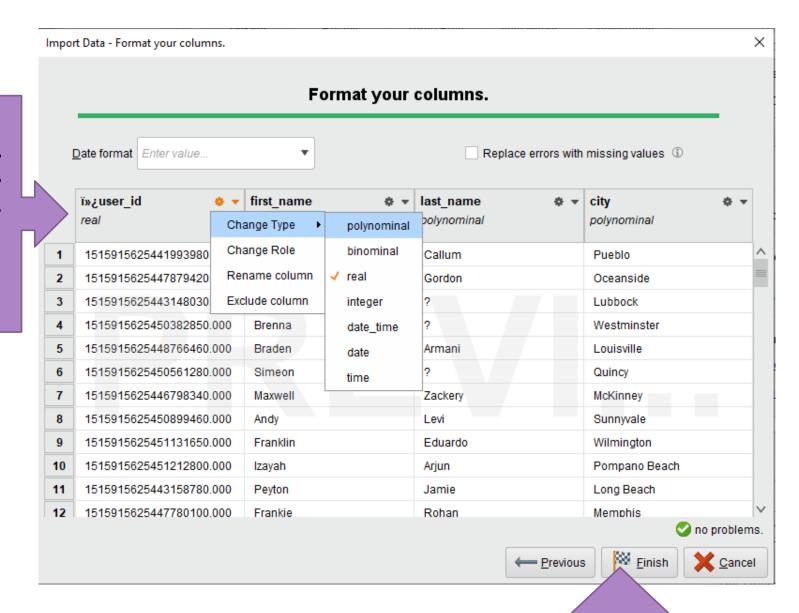
Menggunakan dataset yang sudah di download, akan dibaca dataset kz_users.csv

menggunakan operator Read CSV

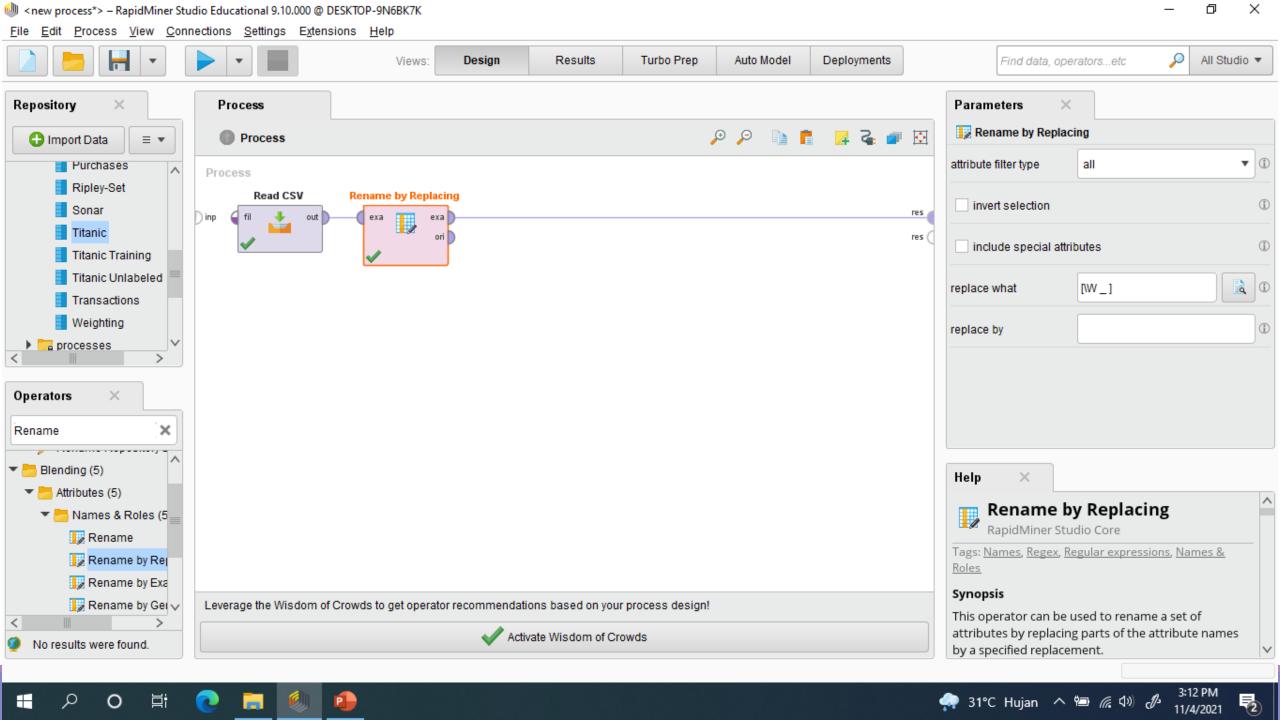


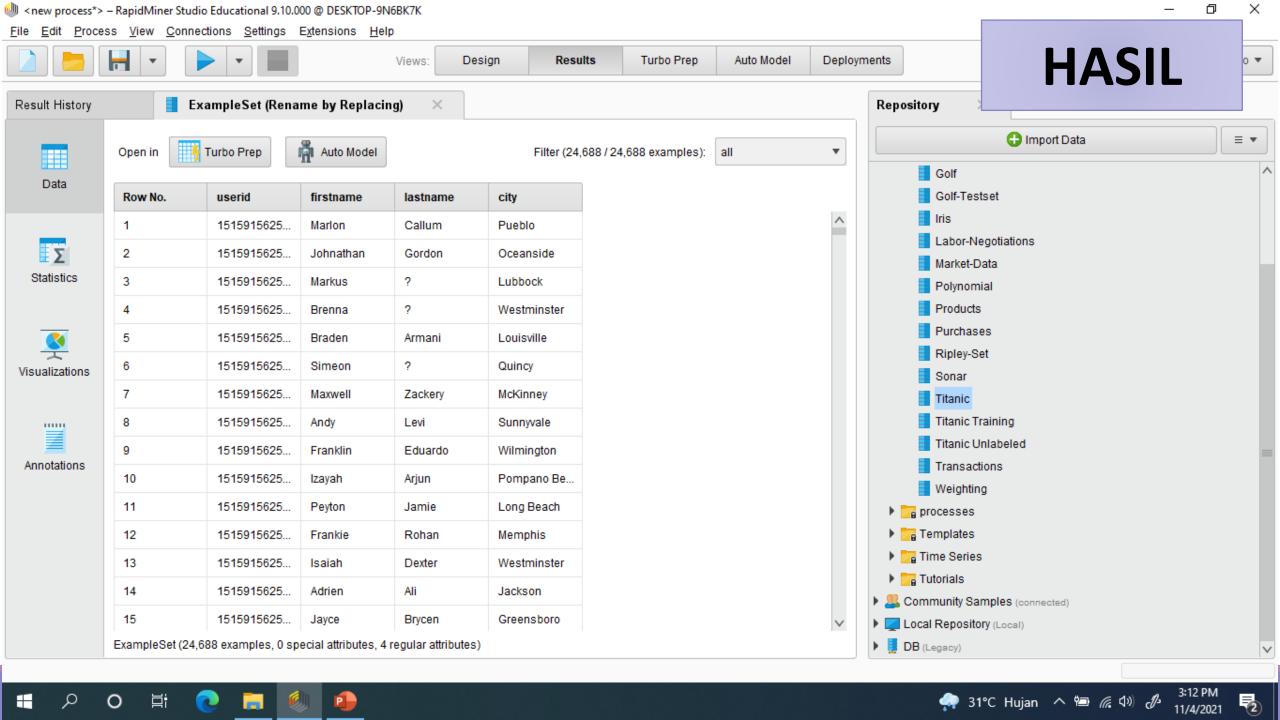
- Double klik pada operator Read CSV tersebut
- ☐ Pilih folder dimana dataset bertipe CSV yang akan dibaca diletakkan
- ☐ Pilih file kz_users.csv Klik Next





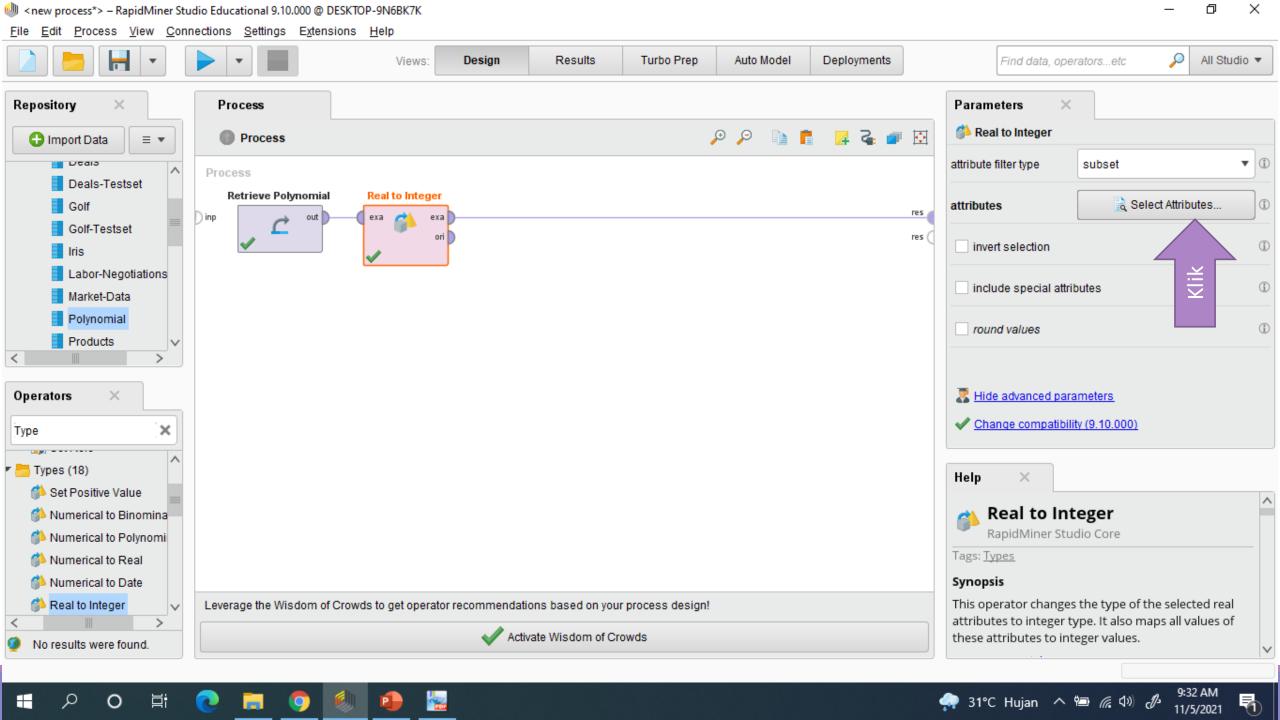
□Pilih operator "Rename by Replacing" – Hubungkan dengan Read CSV
□Double klik pada operator Rename by Replacing tersebut
□Pada Parameter :
•Replace What : diisi dengan [\W _] (untuk menghilangkan symbol yang bukan alphanumeric termasuk symbol _)
□Klik ▷

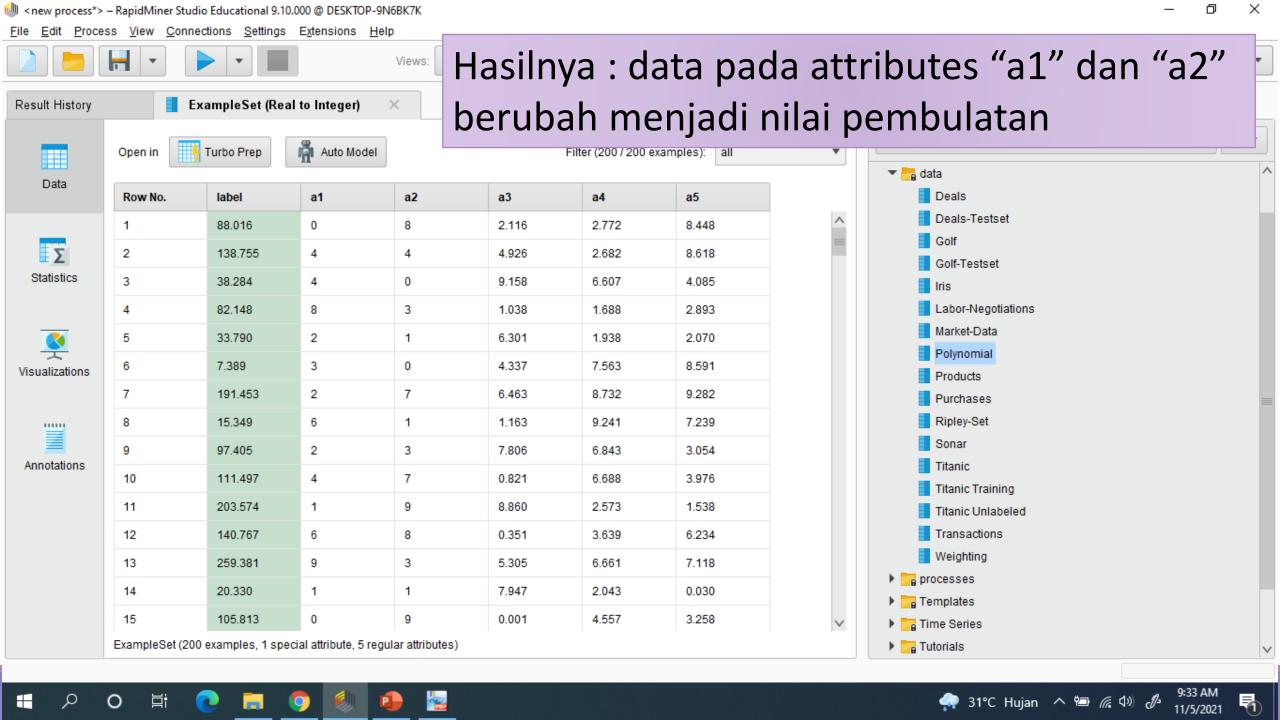




Mengubah Tipe Data Real (Pecahan) Menjadi Integer (Bulat)

Menggunakan data "Polynomial", attribute 1 dan 2 akan diubah menjadi bilangan bulat.
□Retrieve Data "Polynomial"
□Pilih Operator "Real to Integer" – klik
□Pada Parameter :
•Attribute filter type : pilih subset
•Attribute : klik Select Attributes – pindahkan attributes "a1" dan "a2" ke sebelah kanan – klikapply
□Klik ⊳





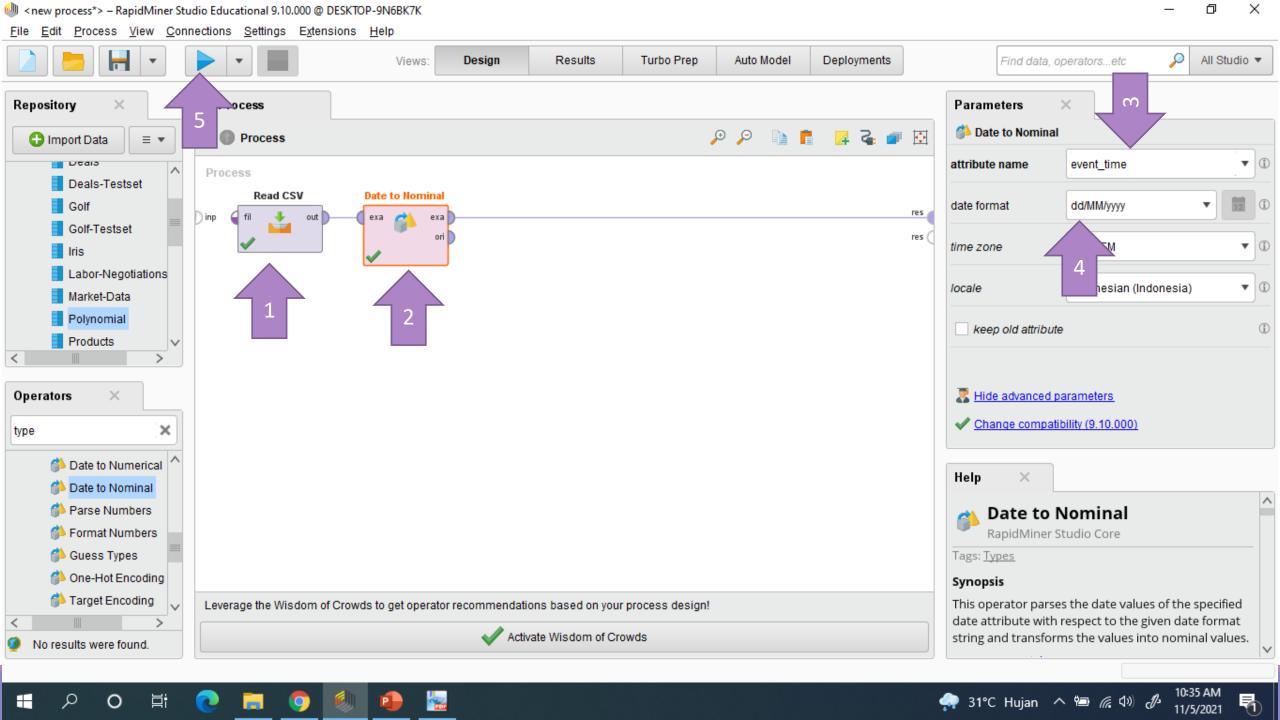
Mengubah Tipe Data

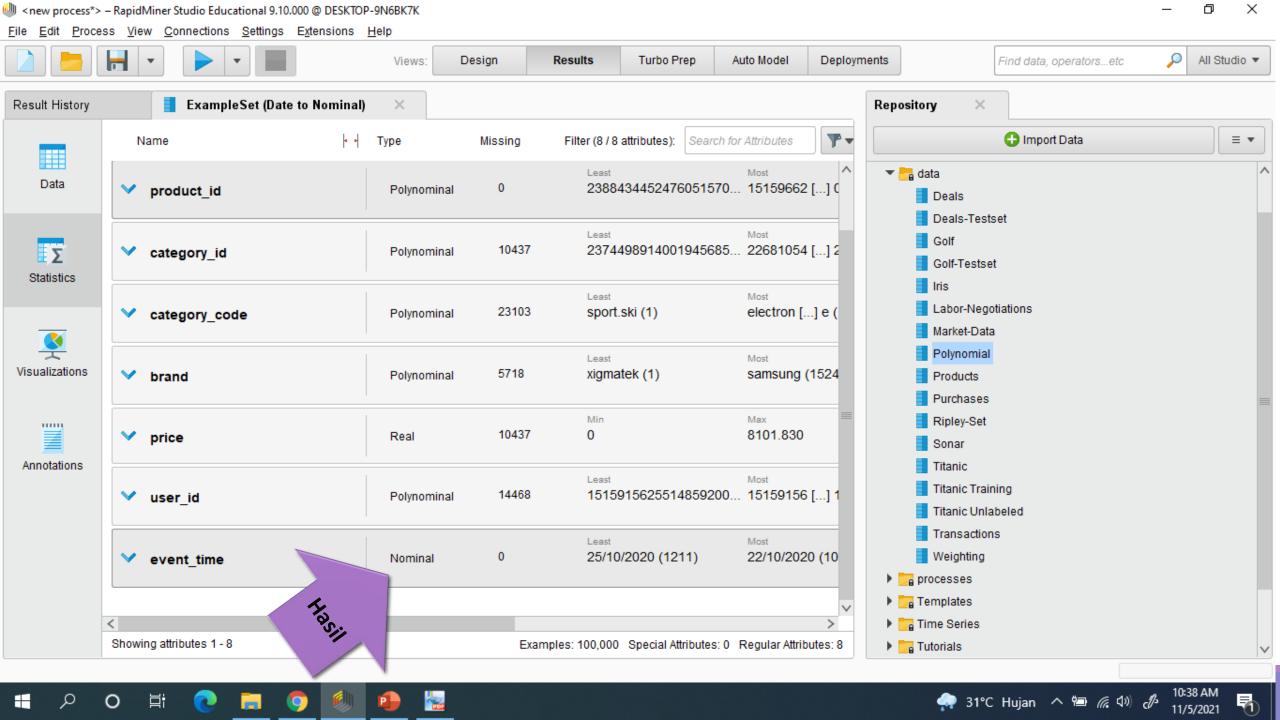
Menggunakan data "electronics-b-100k.csv" yang sudah didownload.

- □Pilih Operator "Read CSV" pilih file "electronics-b-100k.csv" klik next klik next
- □Ubah Tipe Data:
- 1. Order_id, product_id, user_id diubah dari Real menjadi Polynominal
- 2. Klik Finish
- □Tambahkan Operator "Date to Nominal" untuk mengubah tipe data Tanggal (Date) menjadi

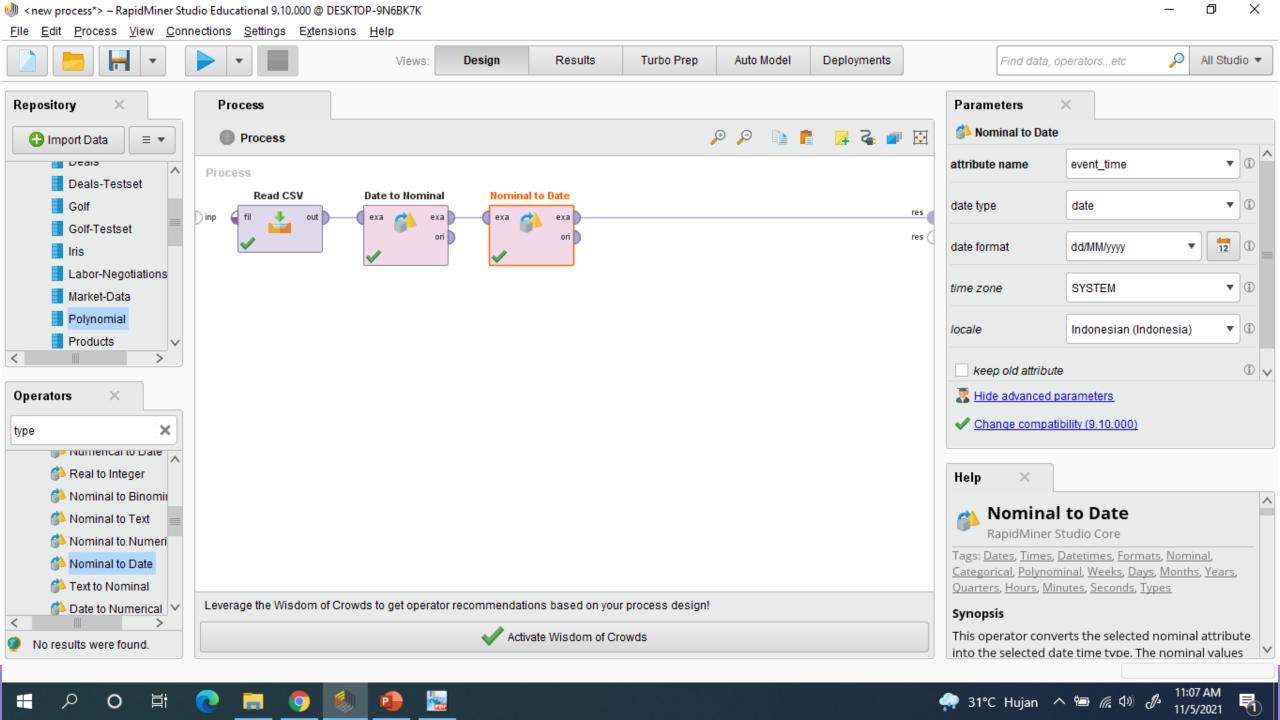
Nominal – klik

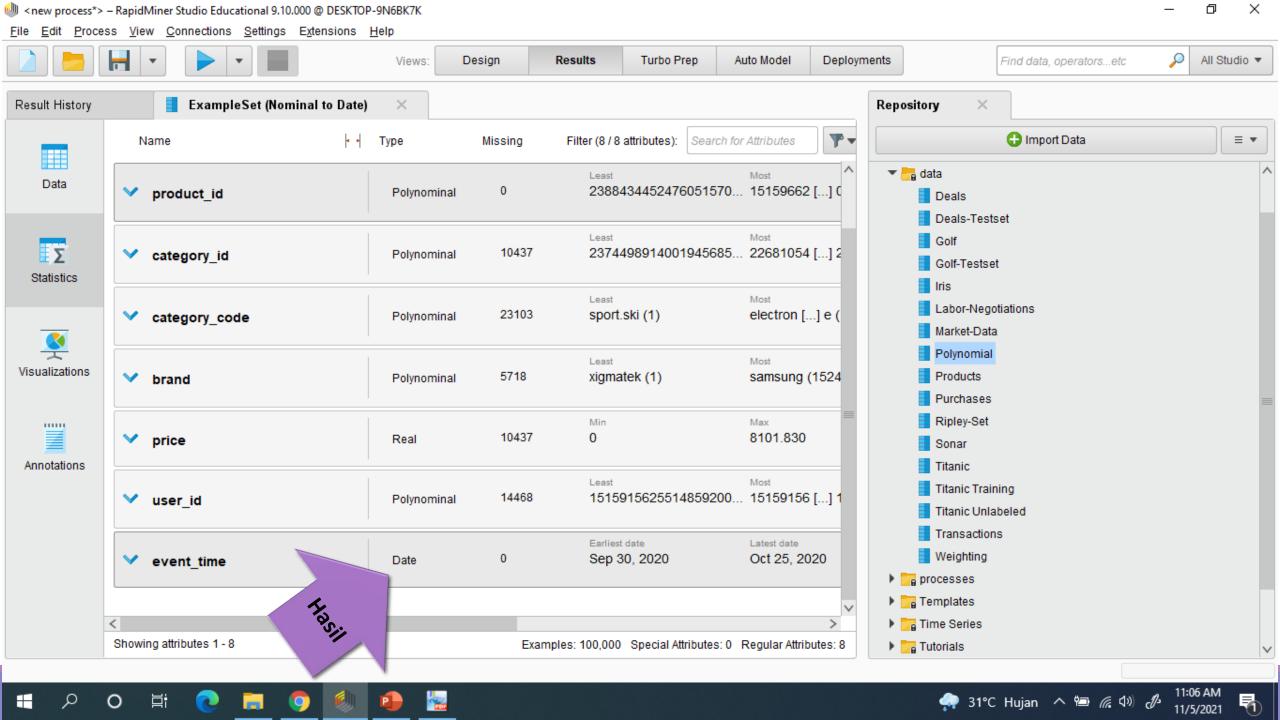
□Pada parameter : a. Attribute name: pilih attribute "Event Time" b. Isikan date format : pilih dd/MM/YYYY (misal dalam format Indonesia) c. Isikan locale : pilih Indonesian (Indonesia) □Klik ⊳





Karena untuk Event Time apabila bertipe Nominal akan berpengaruh pada hasil Analisa data, maka Event Time harus diubah bertipe Date. ☐ Tambahkan operator "Nominal to Date" □Pada parameter : a. Attribute name: pilih attribute "Event Time" b. Isikan date format : pilih dd/MM/YYYY (misal dalam format Indonesia) c. Isikan locale : pilih Indonesian (Indonesia) ⊒Klik ⊳



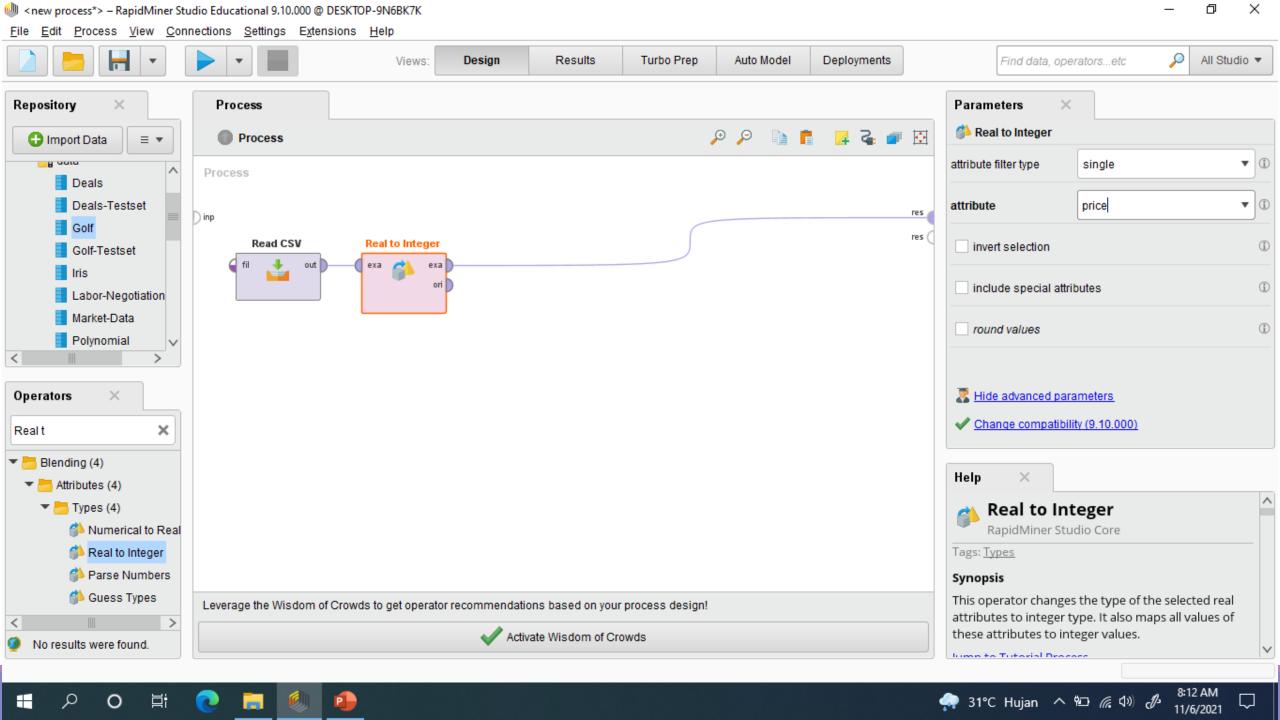


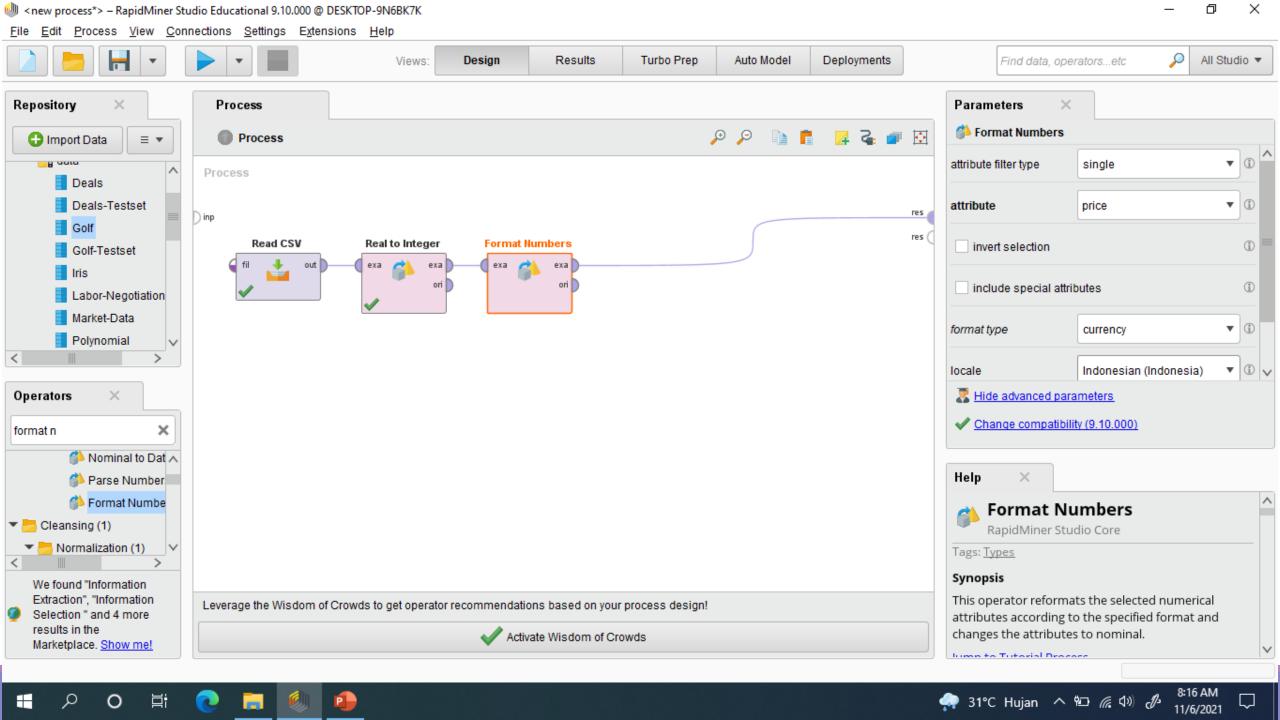
Pada attribute Price akan diubah menjadi bilangan bulat (Integer) dan dimunculkan mata uang Rupiah.

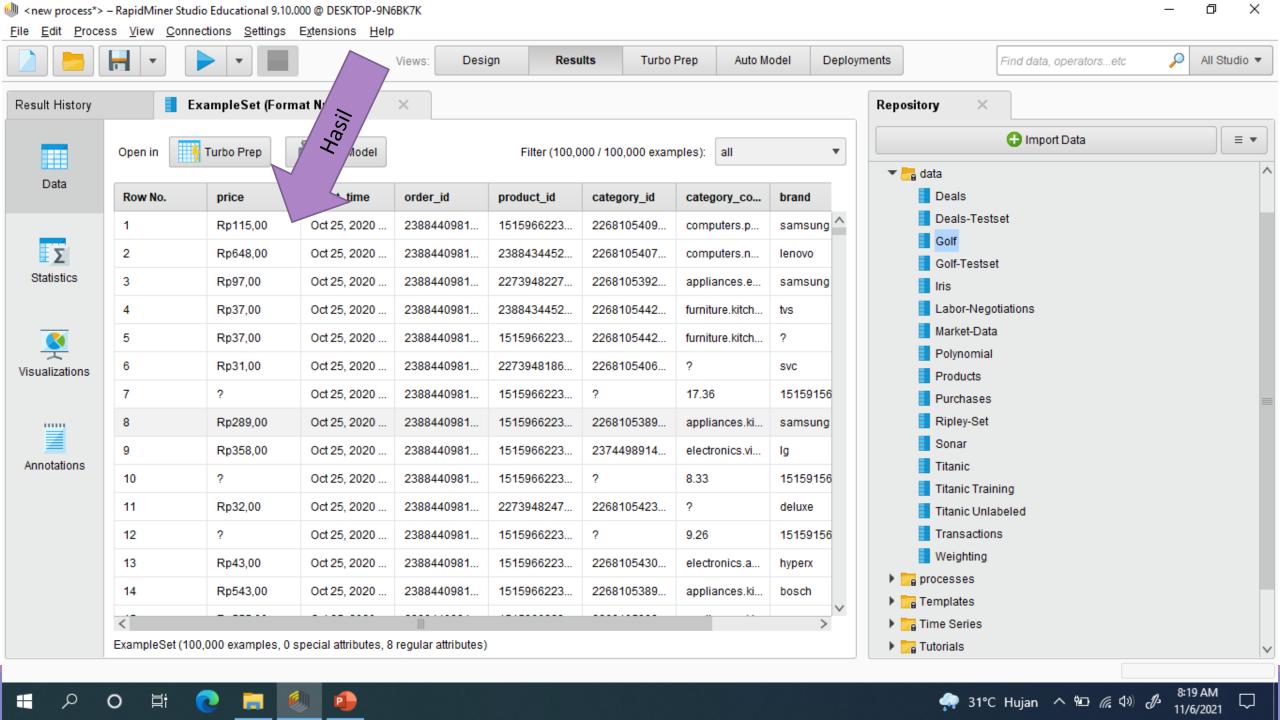
- □Tambahkan operator "Real to Integer" klik
- □Pada parameter :
- a. Attribute filter type: pilih "single"
- b. Attribute: pilih "Price"

- □Tambahkan operator "Format Number" klik
- □Pada parameter:
- a. Attribute filter type: pilih "single"
- b. Attribute: pilih "Price" (Indonesia)
- □Klik ⊳

- c. Format type: pilih currency
- d. Locale: pilih Indonesian







Susunan attribute pada hasil running tersebut masih belum rapi sehingga perlu dirapikan susunannya.

- ☐ Pilih Operator "Reorder attributes" klik
- ☐ Pada parameter, Isikan:
- Attribute ordering : klik define order
- Tentukan urutan attribute yang dikehendaki
- Klik apply
- ☐ Klik ▷

